

深圳大学考试答题纸

(以论文、报告等形式考核专用)

二〇二四～二〇二五 学年度第 二 学期

课程编号	150294 0001	课序号	01	课程名称	信息检索	主讲教师	潘微科	评分	
学 号	20231501 31	姓 名	姚健文	专业年级	计算机科学与技术（高性能班）				

教师评语：

题目：结合大模型的校园学术讲座信息检索系统

一. 基本功能。

(1) **词项**: 使用大模型 API 或开源的中文分词程序(如结巴分词)把中文句子和 query 转换成 terms, 需要详细说明如何在程序中导入/调用外部程序/API, 以及如何进行相关配置和修改等。注: 使用大模型得 10 分, 使用普通中文分词程序得 5 分。

对文档中的内容进行分词, 调用 deepseek 的 api, 输入内容并返回结果, 根据返回的分词进行后续的索引构建

调用大模型需要给定提示词

```
def create_prompt_sub(str):  
    prompt = f"""  
    你需要对我提供的字符串进行分词, 在分词结束后输出分词的结果, 用空格分隔, 此外不需要回答其他内容  
    内容如下:  
    """  
    prompt += str  
    prompt += f"""  
    以上是全部内容, 告诉我分词的结果, 用空格分隔, 不需要回答多余的内容  
    """  
    return prompt
```


生成提示词实现如图, 后续接收返回的以空格分隔的分词

```
def useai_to_sp(prompt):  
    client = OpenAI(api_key="sk-...", base_url="https://api.deepseek.com/v1")  
  
    response = client.chat.completions.create(  
        model="deepseek-chat",  
        messages=[  
            {"role": "system", "content": "你是一个信息检索领域专家, 你的工作就是对用户所给的文档进行分词"},  
            {"role": "user", "content": prompt},  
        ],  
        stream=False  
    )  
  
    print(response.choices[0].message.content)  
    return response.choices[0].message.content.split()
```

调用大模型分词如图, 其中 api-key 隐去, 返回一个分词数组, 后续直接在程序中调用即可得到词组

(2) **交互**: 开发的信息检索系统要求支持较为友好的用户交互, 包括输入框(至少支持中英文两种语言的 query)和返回结果的呈现(包含超链接跳转), 要求界面简洁美观。


使用 tkinter 构建可视化界面, 设置有搜索框、结果预览、文档详情、总结显示等部分




最终效果如图，可以在上方的搜索框中输入查询内容，点击搜索按钮进行搜索，在下方提供示例，下方三个显示区域用于显示预览、详情和总结



搜索后效果如上图，点击结果中的条目会在详情中显示该条目对应文档的全部内容，右侧会显示调用大模型对搜索结果的总结



Query 支持英文搜索，效果如上图



点击打开文件夹按钮可以跳转到对应讲座，完整实现了交互功能

(3) **索引**：要求使用倒排索引（inverted index），不能使用数据库中的关系表来存储文本数据，并分析倒排索引构建的时间复杂度。

```
# 加载文档
folder_path = 'D:\\深大\\课程\\大二下 课\\信息检索\\大作业\\docs'
self.Docstr, self.doc_id_map, self.doc_folder_map = self.load_documents_from_folder(folder_path)
# Docstr中存储文档，2个map存编号与原始编号的映射、与路径的映射
self.N = len(self.Docstr) # 文档总数

# 构建倒排索引
for doc_id in range(1, self.N + 1):
    content = self.Docstr[doc_id - 1]
    lines = content.split("\n")
    title = lines[0].strip()
    self.Title_list.append(title) # 记录标题
```

读取每个讲座文档的内容

```
# 构建正文倒排索引
word_count = {}

# for word in jieba.cut(content):
for word in useai_to_sp(create_prompt_sub(content)):
    word_count[word] = word_count.get(word, 0) + 1

for word, count in word_count.items():
    if word not in self.doc_dict:
        self.doc_dict[word] = {}
    self.doc_dict[word][doc_id] = count
```

根据大模型提供的分词构建倒排索引

时间复杂度分析：

对于 N 个文档，假设平均每个文档有 m 个词项，需要先遍历所有词项，即 $O(N*m)$ ，然后对每个词项插入它所在的文档，该操作使用词典数据结构的时间复杂度为 $O(1)$ ，因此总的时间复杂度为 $O(N*m)$

(4) 权重：要求使用 TF-IDF 作为权重的计算方式，在报告中包含相关的数学公式。要求使用公式编辑工具，不能截图，并对公式中的符号做出解释，对相关的代码实现给出详细的注释，并分析该部分的时间复杂度。

对于查询文档和文档集，它们中的一个词项 t 在文档 d 的 TF-IDF 权重计算公式为：

$$TF - IDF_{t,d} = TF_{t,d} * IDF_{t,d}$$

$$TF_{t,d} = \frac{n_{t,d}}{\sum_k n_{k,d}}, \text{ 其中 } n_{t,d} \text{ 表示 } t \text{ 在 } d \text{ 文档中出现的次数，分母代表 } d \text{ 文档的全部词项次数}$$

$$IDF_t = \log \frac{N}{df_t}, \text{ 其中 } N \text{ 为文档总数，} df_t \text{ 代表 } t \text{ 出现的文档数}$$

在实际的计算中，使用 Wtf 代替 tf 权重

$$WTF_{t,d} = \begin{cases} 1 + \log TF_{t,d}, & TF_{t,d} > 0 \\ 0, & \text{其他} \end{cases}$$

整体权重改进为：

$$WTF - IDF_{t,d} = WTF_{t,d} * IDF_{t,d}$$

```
def compute_tf_idf_scores(self, query_doc, domain="content"):
    """
    计算查询文档与所有文档的TF-IDF点积分数
    :param query_doc: 查询文档字符串
    :param domain: 搜索域 (content/title/author/inviter)
    :return: (分数数组, 查询文档向量长度)
    """
    scores = [0.0] * (self.N + 1) # 初始化分数数组
    query_len_sq = 0.0 # 查询文档向量长度的平方

    # 获取对应域的倒排索引
    inverted_index = self.get_inverted_index(domain)

    # 统计查询文档的词频
    query_word_count = {}
    # for word in jieba.cut(query_doc):
    for word in useai_to_sp(create_prompt_sub(query_doc)):
        query_word_count[word] = query_word_count.get(word, 0) + 1
```

对传入的查询准备计算长度，和其中每个词对全部文档的分数贡献

```

# 遍历查询文档中的每个词
for word, tfI in query_word_count.items():
    # 只处理存在于全局词典中的词
    if word in inverted_index:
        df = len(inverted_index[word])
        idf = math.log(self.N / df) if df > 0 else 0

        # 计算查询文档中该词的权重
        wtfI = math.log10(tfI) + 1 if tfI > 0 else 0
        weightI = wtfI * idf
        query_len_sq += weightI * weightI # 累加到长度平方

    # 遍历包含该词的所有文档
    for doc_id_j, tfJ in inverted_index[word].items():
        # 计算文档j中该词的权重
        wtfJ = math.log10(tfJ) + 1 if tfJ > 0 else 0
        weightJ = wtfJ * idf
        # 累加分数
        scores[doc_id_j] += weightI * weightJ

query_len = math.sqrt(query_len_sq) if query_len_sq > 0 else 0.0
return scores, query_len

```

对每个词，统计出这个词在查询中的 tf 与 idf，然后获取倒排索引中的文档列表，统计它在这些文档中的 tf 与 idf，对应累加它的分数贡献，最终查询的全部词遍历后即可得到该查询对应每个文档所获得的分数

时间复杂度分析：

假设查询中有 n 个词，每个词平均出现 d 个文档，在统计对于查询的权重时复杂度为 $O(n)$ ，在统计在文档集中的权重时的复杂度为 $O(d)$ ，查询中的词一般较少，因此总的时间复杂度为 $O(n)$

(5) 相关性：要求使用余弦相似度作为<query, document>的相关性分值的计算方式，在报告中包含相关的数学公式。要求使用公式编辑工具，不能截图，并对公式中的符号做出解释，对相关的代码实现给出详细的注释（如在实现中做了某种简化或修改需要明确说明），并分析该部分的时间复杂度。

对于查询 q 和文档 d，余弦相似度相关性分数计算如下：

$$Score_{t,d} = \frac{\vec{V}(q) \cdot \vec{V}(d)}{|\vec{V}(q)| \cdot |\vec{V}(d)|}$$

其中分子是两向量的内积，向量中项是查询与文档中的全部词项的权重，分母是这两向量的模长在先前计算 tf-idf 时已经预先计算了查询与文档的长度，且计算权重后已经得到了分数累积数组（即公式中的分子），因此在该过程中只要对结果进行除法处理

```
def compute_cos_similarity(self, scores, query_len):
    """
    计算余弦相似度
    :param scores: TF-IDF点积分数数组
    :param query_len: 查询文档向量长度
    :return: 余弦相似度数组
    """
    cos_sim = [0.0] * len(scores)
    for j in range(1, len(scores)):
        if query_len > 0 and self.doc_lengths[j] > 0:
            cos_sim[j] = scores[j] / (query_len * self.doc_lengths[j])
        else:
            cos_sim[j] = 0.0
        cos_sim[j] = round(cos_sim[j], 4) # 保留4位小数
    return cos_sim
```

对先前计算权重时计算了的分数数组除以它们的长度，得到最终的余弦相似度相关性分数

时间复杂度分析：

由于分数与长度都在先前的步骤中得出，这里只需要对 N 个文档进行简单处理，因此复杂度为 $O(N)$

(6) 排序：要求根据相关性分值的大小对匹配到的 documents 进行排序，返回 top 10 的结果（要求同时显示每个返回的 document 的相关性的分值信息）。需要特别注意效率问题，要求在查询结果的上方显示查询的耗时（单位毫秒）。

为了高效返回，使用堆进行排序，时间复杂度为 $O(\log N)$

```
def get_top_k(self, cos_sim, k=10):
    """
    获取前k个相似文档
    :param cos_sim: 余弦相似度数组
    :param k: 返回的结果数量
    :return: 前k个文档的列表[(文档索引, 相似度)]
    """
    heap = []
    for j in range(1, len(cos_sim)):
        heapq.heappush(heap, (-cos_sim[j], j))

    # 获取最大的k个元素
    top_k = heapq.nlargest(k, heap)
    re_arr = []
    for score, doc_id in top_k:
        if score == 0:
            break
        re_arr.append((doc_id, -score))

    # return [(doc_id, score) for score, doc_id in top_k]
    return re_arr
```

根据先前计算的相似度分数进行排序，返回前 K 大的元素，取 K=10 即为我们需要的返回结果
在搜索前后记录时间，搜索后显示总耗时

搜索结果

文档ID	相似度	文档标题
521660	0.0899	# 学术讲座 《城市发展战略与政策》课程特邀讲座
509300	0.0862	# 讲座：未来互联网试验设施FITI与可信网络架构
526581	0.0775	# 【学术讲座】期刊选题指导讲座
502308	0.0771	# 讲座：高校数字化转型思考
506936	0.0758	# 电子与信息工程学院“悦心小站”主题讲座“向上力——向阳而生，逆光而行”圆满落幕
507738	0.0725	# 【学术讲座】民粹主义的话语本质与社会基础

文档详情

学术讲座 | 《城市发展战略与政策》课程特邀讲座

讲座信息:

讲座题目: 产城融合战略下的企业实践| 城市战略规划编制中的公众参与

讲座时间: 2024.5.24 星期五上午10: 15-11: 40

讲座地点: 深圳大学粤海校区汇文楼H1-204

讲座主持: 陈宏胜, 深圳大学建筑与城市规划学院研究员

主讲嘉宾:

搜索耗时: 1.00 ms 总结耗时: 27617.82 ms

打开所在文件夹

效果如图，上方显示 10 个结果（滚轮查看），下方在详情显示耗时

(7) 综合：要求调用大模型 API 实现某一功能，并将之嵌入到整个系统中，例如，在返回的结果中同时呈现大模型的返回结果和从倒排索引返回的结果，结合大模型支持非文字检索，基于大模型对返回结果进行总结，等。

调用大模型 API 实现基于大模型对返回结果进行总结，具体表现为在返回结果后会出现大模型对于这些结果的分析与总结，提取其中的主题等，效果在（2）中已有展示

```
def create_prompt_sum(self, q, topk):  
    """  
    根据搜索结果的topk 文档构建总结提示词  
    :param q: 原始查询  
    :param topk: 搜索结果列表，格式为[(文档ID, 相似度分数)]  
    :return: 构建好的提示词字符串  
    """  
    prompt = f"""  
    经过搜索排序后挑出最靠前的{len(topk)}篇文档，你需要分析与总结一下它们的内容。  
    原始查询是：“{q}”  
    下面是这些文档：  
    """  
    # 遍历topk结果  
    for doc_id, score in topk:  
        # 获取实际文档内容  
        actual_doc_id = None  
        for ind, ori in self.doc_id_map.items():  
            if str(ind) == str(doc_id):  
                actual_doc_id = ori  
                break  
        if actual_doc_id is None:  
            continue
```

```

# 获取文档内容
content = self.Docstr[ind - 1]
# 获取文档标题（第一行）
title = content.split("\n")[0].strip()
# 添加文档信息到提示词
prompt += f"标题: {title}\n"
prompt += "内容摘要: "
# 添加文档内容摘要（前500字符）
# 首先移除标题行
content_lines = content.split("\n")[1:]
content_without_title = "\n".join(content_lines)

# 截取前500字符作为摘要
summary = content_without_title[:500]
if len(content_without_title) > 500:
    summary += "..."

prompt += summary + "\n"

prompt += f"""
以上是根据查询"{q}"检索出的最相关文档摘要，请你分析并总结这些文档的共同主题和核心内容。
"""

return prompt

```

将返回结果的文档作为提示词的一部分，对大模型描述这些文档的标题与内容

```

def useai_to_sum(prompt):
    client = OpenAI(api_key="sk-...", base_url="https://api.deepseek.com/v1")

    response = client.chat.completions.create(
        model="deepseek-chat",
        messages=[
            {"role": "system", "content": "你是一个信息检索领域专家，你现在需要对用户所给的文档进行总结"},
            {"role": "user", "content": prompt},
        ],
        stream=False
    )

    print(response.choices[0].message.content)
    return response.choices[0].message.content

```

调用大模型对返回结果进行总结，其中 api-key 已隐去

大模型总结

通过对这10篇文档的分析，可以看出它们虽然涉及不同领域，但都围绕“信息”这一核心概念展开，主要呈现以下共同特征：

一、主题分布特征

1. 学术信息传播（占比50%）
 - 包含6场学术讲座信息，涵盖城市规划、互联网技术、法学研究、社会主义理论等多个学科领域
 - 典型如《未来互联网试验设施FITI与可信网络架构》《迈向数字时代的公法研究》等
2. 教育信息化（20%）
 - 高校数字化转型专题（范士喜讲座）
 - 学位法相关的导师培训（周详讲座）
3. 信息处理技能（20%）
 - 学术论文写作指导（2场期刊选题讲座）
 - 信息对策研究（赵丁琪的信息对策奖项）
4. 心理健康信息（10%）
 - “向上力”主题心理讲座


二、核心内容共性

1. 信息生产与传播
 - 7场讲座直接涉及知识生产（学术研究、论文写作）

效果如图

二. 特色功能。

(1) **数据规模**: 下载或用程序爬取的数据规模较大 (超过 1000 个文档)。



名称	修改日期	类型
496612_郁龙余教授讲座回顾: 东方文学是人...	2025/6/19 20:49	文件夹
498009_【深圳大学40周年校庆千场学术活动...	2025/6/19 20:50	文件夹
498021_培训讲座: Wind数据库使用、数据分...	2025/6/19 20:50	文件夹
498127_关于荔园杰出学者讲座第十六期延期...	2025/6/19 20:50	文件夹
498381_离退休党委联合继续教育学院党总支...	2025/6/19 20:50	文件夹
498409_“从0到1创业历程”——管理学院市场...	2025/6/19 20:50	文件夹
498417_王斑教授讲座回顾: 人之彼岸的噩梦	2025/6/19 20:50	文件夹
498673_我院特邀中国工程院杨永斌院士开展...	2025/6/19 20:49	文件夹
498949_【深圳大学40周年校庆千场学术活动 (...	2025/6/19 20:49	文件夹
498972_分析测试技术与应用培训讲座第一百...	2025/6/19 20:49	文件夹
499166_中国国际“互联网+”大赛产业赛道专家...	2025/6/19 20:49	文件夹
499317_深圳大学40周年校庆千场学术活动 (第...	2025/6/19 20:49	文件夹
499354_华为BLM模型与高科技企业营销实践 ...	2025/6/19 20:49	文件夹
499392_关于开展新一届中层领导干部综合能...	2025/6/19 20:49	文件夹
499584_MBA现代医疗管理前沿 (大咖说医管...	2025/6/19 20:49	文件夹
499901_分析测试技术与应用培训讲座第一百...	2025/6/19 20:49	文件夹
500172_分析测试技术与应用培训讲座第一百...	2025/6/19 20:49	文件夹
500233_科学实验秀主持人思维和主持能力讲座	2025/6/19 20:49	文件夹

1,532 个项目 |

数据规模超过 1000 个文档

(2) **邻近搜索**: 支持基于 positional index 的邻近搜索 (proximity search)。

未实现

(3) **通配符查询**: 支持通配符查询 (wildcard query)。

未实现

(4) **多模态展示**: 支持学术讲座页面中的图片、附件等内容的展示。



502182_【深圳大学40周年校庆千场学术活动 (第1305场)】学术讲座 | 浅谈超高层建筑设计.md X

学术讲座 | 浅谈超高层建筑设计 > 502182_【深圳大学40周年校庆千场学术活动 (第1305场)】学术讲座 | 浅谈超高层建筑设计.md

1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27

讲座题目: 浅谈超高层建筑设计

主讲人: 冯秉川, 深圳市建筑设计研究总院有限公司执行总建筑师、深圳市勘察院设计大师、深圳大学建筑与城市规划学院硕士研究生校外导师

讲座主持: 钟中教授

讲座时间: 2025年6月11日 14:30-16:30

讲座地点: 深大建筑学院三栋咖啡厅

联系电话: 976727344

嘉宾介绍:

冯秉川先生通过建筑和城市设计实践参与中国城市化进程, 同时也通过写作、研究、教育等方式对城市化进行反思。无论实践还是反思都有着清晰的空间政治学维度。观察意识形态在城市化过程中的运作机制, 关注空间与主体的相互作用以及当下主体的命运。近年来时间尝试面向儿童的建筑教育, 希望通过建筑帮助儿童身心和谐、快乐成长。

多年从事大型公建建筑设计、城市设计获得多项国家、省、市建筑设计奖项, 主持设计了南方科技大学校园规划、深圳大沙河文体中心、深圳书城湾区店、深圳深业泰然大厦、南宁规划展示馆、深圳香之阁总部大厦、深圳国恒民生金融大厦、深圳光明公共服务平台等重要项目。

从事建筑设计的同时, 善于跨界整合建筑设计、城市规划、景观设计、灯光设计、公共艺术等不同领域提升城市的整体艺术水准。曾参加深圳公共雕塑展、珠海公共艺术展、西安公共艺术展、深圳“光之公共艺术展、深圳香港城市建筑双城双年展等。

冯秉川

主要项目:

南方科技大学校园规划

image_2_20239_8987581 image_3_20239_8112081 image_4_20239_8827263 image_5_20239_8288659 image_6_20239_8159995

搜索后跳转图片、附件展示如图

(5) **按域检索**：支持按域检索，要求至少包含 3 个不同的“域”，例如，“讲座题目”、“讲座摘要”、“邀请人姓名”、“主讲人姓名”、“主讲人简介”等。

实现了按正文、讲座标题、主讲人姓名、邀请人姓名查询，通过分别构建倒排索引后选择对应的倒排索引查找实现

文档检索系统

搜索内容: 生命

搜索域: 正文

搜索

示例: 信息 举办 知识 学术 生命 大学 联邦 辅助 原型 计算

搜索结果

文档ID	相似度	文档标题
506393	0.1004	# 学术讲座——《海浪——海洋的节拍》
506958	0.1001	# 学术讲座——不同应用场景下的信息检索
524024	0.0973	# 【学术讲座（九）】如何进入超越论生命的“活的当下”
511208	0.0893	# 【学术讲座】矢志国防 向海图强
525296	0.0890	# “如何进入超越论生命的‘活的当下’”学术讲座在马克思主义学院顺利举办
532412	0.0880	# 学术讲座——飞跃整个地球来看你 - 智利海沟航次纪实

文档详情

学术讲座——《海浪——海洋的节拍》

时间: 2023年11月2日10:15

地点: 丽湖校区四方楼北311

主讲人: 孙建教授

中国海洋大学海洋与大气学院

2000年获中国海洋大学海洋科学学士学位, 2005获得中国海洋大学海洋科学博士学位。主要从事台风浪和风暴潮动力过程、长距离传播的涌浪特征分析和机理, 以及海洋锋对海浪SAR成像和海浪要素反演的影响等研究。在海洋科学知名学术期刊发表论文30余篇, 主持国家自然科学基金联合基金重点项目与多项国家自然科学基金面上

搜索耗时: 1.00 ms 总结耗时: 16707.26 ms

打开所在文件夹

大模型总结

根据对10篇文档的分析, 这些讲座虽然主题各异, 但都围绕“生命”这一核心概念展开, 主要呈现以下三个维度的研究视角:

1. 海洋生命科学领域 (占比50%)

- 聚焦海洋生态系统研究, 如孙建教授《海浪——海洋的节拍》探讨海洋动力过程, 李芯芯博士两次《智利海沟航次纪实》研究有机碳循环与气候变化关系

- 包含海洋技术应用, 如朱靖博士《矢志国防 向海图强》涉及光纤水声探测技术

- 展鹏博士两次《红海趣谈》关注珊瑚生态系统与海洋环境互动

2. 生命哲学研究 (占比20%)

- 陈员博士的超越论生命讲座深入探讨胡塞尔现象学中的“活的当下”概念

- 提出超越论生命是持续构造的存在状态, 涉及意识哲学与生命本体论

3. 生命科学技术 (占比30%)

- 林康凤博士《分子诊断技术与应用》展示PCR等分子检测技术

总结生成完成

根据搜索按钮旁的下拉框选择要搜索的域，上图按正文搜索

文档检索系统

搜索内容: 生命

搜索域: 标题

搜索

示例: 信息 举办 知识 学术 生命 大学 联邦 辅助 原型 计算

搜索结果

文档ID	相似度	文档标题
524024	0.1624	# 【学术讲座（九）】如何进入超越论生命的“活的当下”
534689	0.0934	# 生命与海洋科学学院实验中心技术与应用培训讲座（第六期）：激光共聚焦显微镜的原理
517094	0.0904	# 生命与海洋科学学院实验中心技术与应用培训讲座第一期 气相色谱质谱联用仪（安捷伦）
517142	0.0844	# 生命与海洋科学学院“职得”系列讲座（8）：深圳市编制教师招聘考试讲座培训会
522078	0.0822	# 生命与海洋科学学院实验中心技术与应用培训讲座第三期 圆二色光谱仪（Jasco J-815）
524549	0.0819	# 生命与海洋科学学院实验中心技术与应用培训讲座第四期 激光共聚焦显微镜（Zeiss LSM

文档详情

【学术讲座（九）】如何进入超越论生命的“活的当下”

主讲人: 陈员南昌大学人文学院教师

时间: 2024年6月14日（星期五）下午2:00

地点: 汇文楼1600会议室

主讲人简介:

陈员, 南京大学哲学博士, 南昌大学人文学院教师。主要研究方向: 胡塞尔现象学, 身体现象学, 近代认识论, 中西比较哲学。出版著作《胡塞尔身体现象学研究》(2024), 在《南京大学学报》等期刊发表论文多篇, 主持、参与国家级、省部级课题多项。

搜索耗时: 1.00 ms 总结耗时: 21551.88 ms

打开所在文件夹

大模型总结

文档总结与分析

1. 共同主题

这些文档的共同主题围绕“生命”展开, 但具体涉及多个领域, 包括:

- **哲学与现象学***: 探讨超越论生命的“活的当下”及其哲学意义。

- **生命科学与技术***: 涵盖蛋白质组学、植物免疫机制、显微镜技术等。

- **教育与职业发展***: 如教师招聘考试培训。

- **合规与风险管理***: 学院合规建设与经济风险防控。

2. 核心内容

1. **哲学与现象学**

- 讲座探讨胡塞尔的“活的当下”概念, 强调其作为超越论生命的存在状态, 而非简单的生物本能。

- 提出通过现象学分析和自我意识进入这种状态的方法。

2. **生命科学与技术**

- **蛋白质组学***: 介绍新技术如空间和单细胞蛋白质组学, 用于解码生命微观世界。

- **植物免疫机制***: 何祖华院士分享植物抗病调控基因的

总结生成完成

上文按标题搜索，返回的文档不同，功能实现成功

(6) **用户交互：**支持友好的用户交互，例如，通过字体标红或黄色阴影等方式帮助用户快速理解返回的结果。

搜索内容: 信息

示例:

信息

举办

知识

学术

生命

大学

联邦

辅助

原型

计算

搜索结果

文档ID	相似度	文档标题
521660	0.0899	# 学术讲座 《城市发展战略与政策》课程特邀讲座
509300	0.0862	# 讲座: 未来互联网试验设施FITI与可信网络架构
526581	0.0775	# 【学术讲座】期刊选题指导讲座
502308	0.0771	# 讲座: 高校数字化转型思考
506936	0.0758	# 电子与信息工程学院“悦心小站”主题讲座“向上力——向阳而生, 逆光而行”圆满落幕
507738	0.0725	# 【学术讲座】民粹主义的话语本质与社会基础

文档详情

深圳职业技术大学教育技术与信息中心副主任(主持工作), 曾任哈尔滨工业大学(深圳)网络与计算中心主任。

中国高等教育学会教育信息化分会副秘书长

深圳市高校教育化学会副会长

深圳市智慧城市研究院首席专家

深圳市信息行业专家委员会专家

信息中心

2023年9月11日

搜索耗时: 2.00 ms 总结耗时: - ms

打开所在文件夹

在返回的文档详情中对与查询相关的词进行高亮显示，友好的用户交互实现成功

(7) **存储优化:** 优化字典 (dictionary) 或倒排记录表 (postings list) 等的存储空间复杂度。

通过添加停用词，减少总的词汇量，进而减少倒排索引的存储空间

```
for word in useai_to_sp(create_prompt_sub(content)):
    word_count[word] = word_count.get(word, 0) + 1

for word, count in word_count.items():
    if word in self.stop_word:
        continue

    if word not in self.doc_dict:
        self.doc_dict[word] = {}
    self.doc_dict[word][doc_id] = count
```

存储优化实现如图

(8) **排序**：在对返回的结果进行排序时，考虑除余弦相似度之外的其他合理因素，例如，document 的时效性等。需要明确说明所采取的具体方式和实现的细节。
未实现

(9) **纠错**：支持 query 建议或 query 纠错（方法不限于教材中的方法），能够给出 1-3 个合理/正确的候选 query。

利用大模型进行查询纠错

```
prompt += f"""
以上是根据查询"{q}"检索出的最相关文档摘要，请你分析并总结这些文档的共同主题和核心内容。
如果文档数少于5个，给出可能的查询纠错以及你的候选查询建议
"""

return prompt
```

搜索内容: 知shi

搜索域: 正文

搜索

示例: 信息 举办 知识 学术 生命 大学 联邦 辅助 原型 计算

搜索结果

文档ID	相似度	文档标题
507386	0.1171	# 创新创业教育中心“优鹏计划·创新领航系列讲座”第三十五讲: 62块钱起家, 我如何做
536325	0.1151	# 第二届全国大学生职业规划大赛校赛预热系列讲座回顾:《职规赛选手进阶培训》顺利结
535783	0.0822	# 第二届全国大学生职业规划大赛校赛预热系列讲座: 职规赛选手进阶培训

文档详情

创新创业教育中心“优鹏计划·创新领航系列讲座”第三十五讲: 62块钱起家, 我如何做到资产上亿?

主讲嘉宾: 熊大

时间: 11月16日(星期四) 15: 00-16: 30

地点: 创新创业教育中心南校区秋瑟冬第209

主讲人简介: 熊大

62块钱来深圳, 连续4次创业, 目前资产上亿

深圳知名企投家, 房有会咨询公司CEO

搜索耗时: 1.52 ms 总结耗时: 17567.35 ms

打开所在文件夹

大模型总结

围绕全国大学生职业规划大赛, 提供备赛技巧(如职业探索方法、评审标准解读)和成功案例(国赛金奖经验), 强调职业规划对个人发展的重要性。

3. **关联性**:

虽然“知shi”的原始查询较模糊, 但检索结果均匹配“知识”的实用场景——通过讲座传递**创业知识**和**职业规划知识**, 符合用户可能的潜在需求(如获取职业发展相关资讯)。

查询优化建议:

1. **可能的纠错**:

-

原查询“知shi”可能是拼音输入错误, 建议修正为“知识”或“职业知识”。

- 若用户想特指某领域(如创业/职业规划), 需补充关键词。

2. **候选查询建议**:

- 通用方向: “大学生创业知识 职业规划讲座”

- 精准方向: “如何赚第一桶金 职业规划大赛备赛技巧”

- 扩展方向: “深圳大学创业讲座 职业规划培训报名”

如需更精确的结果, 建议提供更具体的查询意图(如侧重创业案例或职赛规则)。

纠错如图，利用大模型给出纠错后的查询，以及对查询的优化建议

(10) **个性化**：个性化邮件订阅和推荐功能等。

在搜索内容下提供个性化推荐的查询

搜索内容:

示例:

信息

举办

知识

学术

生命

大学

联邦

辅助

原型

计算

其他自认为比较有特色的地方（可自行说明）。

① 查询过滤：对于相似度较低或为 0 的结果过滤不显示

如上图中返回少于 10 个结果，是因为已经对结果进行过滤